

1. 질의사항

가. AI 영업비밀 문서 등급 분류

순번	질의사항	상세
1	AI 영업비밀 등급 분류에 사용할 분류 기법 종류	• 현재 파악한 등급 분류 기법의 종류는 아래와 같음 • 아래 분류 기법이 최종 확정된 기법 목록과 다르다면 최종 확정된 기법 목록 요청 - 모델 기반 분류 기법 - 룰 기반 분류 기법
2	등급 분류의 전체 워크플로우 과정	• 현재 파악한 등급분류 워크플로우 과정은 아래와 같음 • 아래 워크플로우 과정이 실제 과정과 다르거나, 최종 확정된 과정이 아니라면 각 분류 기법 간 연계 및 최종 등급 판정 방법을 포함한 전체 워크플로우 과정에 대해 정리 요청 1. 입력 문서(HWP, DOCX, PDF 등)에서 텍스트를 추출. 정규화 및 개인정보 마스킹을 수행. 2. 긴 문서를 처리하기 위해 최대 512 token 단위의 청크로 분할. 각 청크에 대해 KF-DeBERTa 모델 추론을 수행. 3. KF-DeBERTa가 출력한 청크별 클래스 logits에 Temperature Scaling을 적용하여 모델의 Over-confidence을 완화한 다음, Softmax를 통해 클래스별 확률 벡터를 생성. 4. 생성된 청크별 확률 벡터를 집계 - 고위험 등급(TS, S1): 문서 내 일부 영역에서 민감 정보가 포함될 가능성을 고려하여 Max Pooling 기반 집계 - 일반 등급(S2, S3): 문서 전체 특성을 반영하기 위해 길이 가중 평균 기반 집계 5. 집계된 결과를 재정규화하여 최종 문서 단위 확률 벡터를 생성. 6. 고위험 등급(TS→S1→S2) 순으로 임계값을 만족하는지 검사하여 우선적으로 상위 보안 등급을 선택하고, 해당 조건을 만족하지 않을 경우 최대 확률(argmax)에 따라 최종 등급을 결정

2-1	GPU를 사용할 수 있는 환경에서 추가 / 변경되는 워크플로우 과정	- 예시 - RAG(LLM) 추가 - 분류 기법 추가 - 반환하는 결과 항목의 종류, 정보 등
2-2	100페이지가 넘는 대용량 문서의 처리 방법 및 예상 처리 시간	100 페이지 이상의 대용량 문서 처리 시 예상되는 처리 시간 - 대용량 문서 처리에 사용할 전처리 방법 등
3	등급 판정 완료 후 반환하는 결과 항목의 종류	- 현재 배포된 PoC에서 반환되는 항목이 최종 확정된 항목인지 확인 필요 - 최종 확정이 되지 않았다면, 추후 추가될 항목 목록 전달 요청 - GPU 사용 가능 여부에 따른 반환 항목의 종류 구분 필요
3-1	등급 판정 결과의 SVM 점수 산정 방식	
3-2	등급 판단 근거(XAI) 제시에 사용하는 방법	- XAI : 인공지능 모델이 특정 결과나 의사결정을 도출한 과정을 사용자가 이해할 수 있도록 설명하고, 해당 설명을 바탕으로 합리적인 의사결정을 지원하는 방법론 - 이전에 우리 KL 측에서 PoC를 진행했을 당시 BERT 모델의 내부 신호(Attention Weight, Gradient Saliency 등)를 바탕으로 핵심 단어와 중요 청크를 추출한 다음 LLM을 통해 간략한 보고서를 생성 - 현재 구현된 분류 엔진에도 이러한 XAI 기법을 사용하여 판정 근거를 제시하는지, 만약 사용하지 않는다면 어떤 방법을 사용하는지 설명 요청
4	룰 기반 분류 방식에 대한 설명	- 사전 정의한 약 400개의 키워드가 문서 내 출현 빈도에 따라 등급 판정을 진행하는 것으로 파악됨 - 추후 룰 기반 분류 방식의 개선이 있을 예정인지? - 키워드는 관리자가 관리 할 수 있도록 할 예정인지?
5	현재 구축 기준 DB 및 Vector DB 명세서 제공 요청	- RDBMS, Vector DB 테이블 명세서 - RDBMS, Vector DB 칼럼 명세서

6	고려중인 관리시스템과 분류 엔진 간 통신 방법	• 메일로 전달드린 'AI 분류 엔진 연계를 위한 API 예상 통신 방안.pdf' 검토 요청
7	실무자 개입 기반 튜닝(능동 학습 체계)에 대한 설명 및 워크플로우 과정	• 능동 학습에 사용할 데이터 수집 / 전처리 / 저장 방법 • 능동 학습 진행 순서 • 능동 학습이 완료된 모델의 성능 검증 방법 • 능동 학습 소요 시간 및 자원, 성능 지표 등

나. AI 기반 영업비밀 등급 분류 학습 및 샘플 문서 생성 및 관리

순번	질의사항	상세
1	확정된 샘플 문서 생성 기법 및 전체 워크플로우	• 샘플 문서 생성 과정 및 워크플로우
2	샘플 문서 내용 검수 방안	• 샘플 문서를 통해 학습한 모델의 성능이 목표치보다 떨어질 경우 조치 방법 - 샘플 문서 추가 생성, 샘플 문서 생성 프롬프트 변경 등 • 보안 가이드라인 기반 라벨링 매핑 방법
3	현재 분류 모델의 성능 지표 현황	• 모델 기반 분류 방식의 성능 지표 • 다른 분류 기법(룰 기반, 유사 문서 검색 기반 등)의 성능 지표 • 전체 분류 엔진의 성능 지표 • 성능 지표 예시 - F1-Score, Precision, Recall, Accuracy 등

상기 내용 검토 후 가능한 범위에서 자료 및 검토 결과를 전달해 주시면 감사하겠습니다.